數位分身專案

個人分身的建置方法與驗證協議

研究進度報告 · 2026 年 9 月

目錄

1	**專案目標**	本專案要達成的架構、驗證與邊界三項目標，並以既有兩條技術路線作為背景對照	1–6
2	**能力邊界**	分身在態度層可用、在行為層失效的實證數據，據此界定可承諾的範圍	7–8
3	**系統架構與驗證**	四段架構、測量工具的取捨、釋出閘門與更新機制，以及底層模型實驗	9–21
4	**對標與未來規劃**	國內外既有案例與 Andrew Ng 分身的缺口，以及語言、視覺、聲音三階段規劃	22–24

專案目標：建立低成本且可驗證的個人分身

本專案產出

核心宗旨　建立低成本、可驗證的個人數位分身，重現一個人的說話風格、思考邏輯與價值觀，用於經驗與智慧的傳承。

01

架構目標

02

驗證目標

03

邊界目標

前情提要：兩條既有技術路線的比較

文獻既有

	GenAgents Stanford / Google DeepMind · arXiv 2411.10109	女媧 Nuwa 開源社群 · alchaincyf/nuwa-skill
資料來源	本人自述： 2 小時訪談 × 1,052 人	公開資料：演講、貼文、 Podcast 、文章
建置成本	極高（累積 2,000 小時以上）	極低（自動抓取，數小時內完成）
測量目標	個體差異——這個人與他人差在哪	思維框架——這個人如何推理
輸出形式	一組人格向度分數	可執行的心智模型與決策啟發式
品質控制	心理計量學：效度、信度、常模	三重驗證：跨域複現、生成力、排他性
驗證方式	與本人兩週後重測結果比對	與本人公開表態過的立場比對
主要限制	學術規格，無法規模化	拿不到本人自述，須靠驗證過濾雜訊

01

GenAgents

Stanford / Google DeepMind
學術訪談法

02

女媧 Nuwa

開源社群
公開資料蒸餾法

學術訪談法：以大規模自述資料建立分身

文獻既有

1 分層抽樣

1,052 位受測者
依年齡、性別、種族、地區

2 收集自述

每人 2 小時訪談
加四項測量工具

3 建立分身

自述放入提示詞
不重新訓練模型

4 驗證準確度

與本人兩週後
重測結果比對

值得借鑑的三個設計

- 不重新訓練模型
- 採用他人設計的訪談腳本
- 評估時剔除可被猜中的題目

01

GenAgents

Stanford / Google DeepMind
學術訪談法

02

女媧 Nuwa

開源社群
公開資料蒸餾法

蒸餾流程：從公開資料到可執行的分身

文獻既有

1 選定檔位

快速 / 標準 / 深度
決定調研維度數

人工

2 多維度調研

分頭抓取著作、對話、
表達素材

自動

3 三重驗證

15–30 個候選論點
篩出 3–7 個

自動

4 提煉框架

心智模型、決策啟發式
表達 DNA

自動

5 生成 Skill

可直接載入使用的
人格檔案

自動

行為層驗證：分身答得出觀點，預測不了行為

文獻資料 · 本專案分析

問觀點（態度層）

準

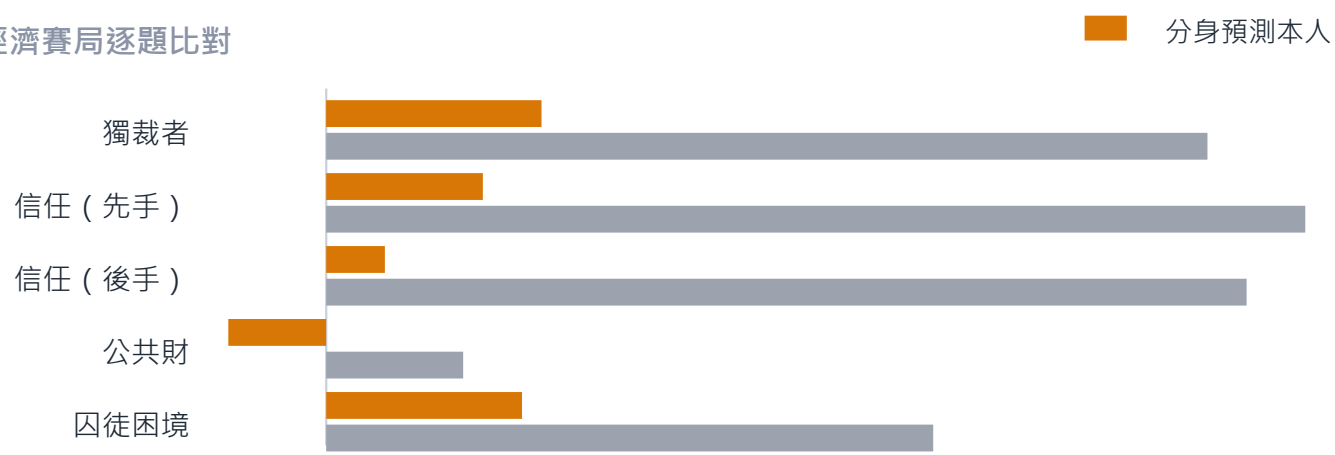
對社會議題的立場、看法

預測行為（行為層）

不準

實際怎麼分錢、要不要信任對方

佐證：五個經濟賽局逐題比對



本人自己是穩定的，
所以不是題目有問題——
是分身預測不到。

資料來源： Park et al., arXiv:2411.10109v3 ；公共財賽局本人重測僅 0.07 ，信度不足，不列入判定。

應用邊界：態度層可落地，行為層不予承諾

本專案產出

態度與觀點層級

GSS 一致性 0.83

實際意義： 177 題中答對 65.7%

本人兩週後重測為 79.5%

適用：常見問題回覆、教學與研究理念重現

行為與決策層級

賽局 correlation 0.03–0.11

即使具備本人兩小時訪談資料亦無法預測

僅有公開資料之方法表現只會更低

不適用：具體決策預測，本專案不予承諾

0.83 並非準確率，而是相對於本人自身重測穩定度的比值。

行為層預測為該領域尚未解決之共同問題，亦為潛在的技術空缺。

技術定位：介於學術訪談法與蒸餾法之間

本專案產出

	學術訪談法 Stanford	公開資料蒸餾法 開源方案	本專案 混合法
資料來源	本人自述 1,052 人 × 2 小時訪談	公開資料 演講、貼文、音訊節目	本人自述 + 公開資料
建置成本	極高 累積 2,000 小時以上	極低 數小時內完成	中 本人投入約 3 小時
品質控制	心理計量學 效度、信度、常模	三重驗證 跨域複現、生成力、排他性	沿用三重驗證 另加心理計量驗證
主要限制	學術規格 難以規模化	無本人自述 須以驗證過濾雜訊	可取得本人自述 但預算規模受限

本專案架構：低成本蒸餾流程 + 本人自述資料 + 心理計量驗證工具

系統架構：資料、蒸餾、驗證、釋出

文獻資料 · 本專案分析



多了本人自述

沿用既有流程

本專案原創

系統架構 ①②：資料層與蒸餾層

文獻資料 · 本專案分析



測量工具：四項工具的層級、題數與構面

文獻既有

層級	工具	題數	構面與內容	取得方式
素材層 質性社會學	AVP 訪談腳本	124 題	半結構式訪談，開場為極開放題「說說你的人生故事」，時限 625 秒。 依序涵蓋人生轉捩點、家庭與重要他人、社區、日常作息、政治立場。每題設秒數上限。	文獻附錄全文刊出
態度層 社會學	GSS 綜合社會調查	177 題	對社會議題的立場，如墮胎、死刑、槍枝管制、對各機構的信任度。 評估時剔除 27 題人口統計題與 27 題與訪談措辭雷同者，避免靠背景推測或照抄得分。	官方免費公開
人格層 人格心理學	BFI-44 大五人格	44 題	五個維度：外向性 8、親和性 9、嚴謹性 9、神經質 8、開放性 10 題。 五點量表，各維度取平均；其中 16 題為反向題，以 6 減原分換算。	學術用途免費 具台灣驗證繁中版
行為層 行為經濟學	五個經濟賽局	5 局	獨裁者測利他、信任賽局先手測信任、後手測互惠、公共財測合作、囚徒困境測合作與自利的取捨。 以實際金額作答，單局獎金上限 8 至 10 美元。	文獻載明完整參數

工具取捨：保留、改寫、自建

本專案產出

決定	工具	題數	判定理由	後續作業
保留	BFI-44 大五人格	44 題	免授權費，具台灣驗證繁中版（α .73–.83），結果可國際對比	取得繁中版全文（需學術資料庫權限）
改寫	AVP 訪談腳本	124 → 40–60 題	原版題目為美國社會議題；惟開放式開場與降低社會期許偏誤的問法具參考價值	改寫為中文學術場景版，涵蓋生涯、教學、研究品味、指導原則
自建	專業領域態度題庫（取代 GSS）	60 → 40 題	GSS 為美國社會議題，與應用場域無關聯，須整份替換	六個面向各 10 題，經篩選後保留 40 題（詳見次頁）
暫不用	五個經濟賽局	5 局	文獻原始資料顯示此層級預測力接近於零	列為後續階段之開放研究問題

自建題庫的六個面向（各 10 題）

研究品味 | 指導原則 | 教學理念 | 對 AI 的立場 | 學術倫理 | 職涯與價值觀

系統架構 ③：驗證層

本專案產出



驗證瓶頸：改採免標準答案的兩階段協議

本專案產出

第一階段　資料蒸餾

公開資料與本人自述經蒸餾流程產出分身

版本凍結，並記錄資料清單與模型版本

第二階段　免標準答案之驗證任務

判斷依據改採三種來源

既定計分規則　·　專家判斷　·　天然對照組

驗證任務：三項任務的依據皆非本人逐題答案

本專案產出

① 標準化量表

- 主要工具為 BFI-44 繁中版，並以公有領域之 IPIP-IPC（支配 × 親和二軸）替代 DISC 之功能位置
- DISC 評估：商業版題目無法取得，唯一開放版本（16 題）缺乏信度資料，且學界評價偏負面 → 列為輔助工具，結果定位為風格描述
- 分身同題作答三次以檢視穩定度，並與本人自評及 2–3 位熟識者之他評比對

② 課程框架設計

- 題目：設計指定課程之 12 週課綱，並說明排序理由
- 三門課程：已開授者（具真實課綱可對照）、專長內未開授者、專長外者
- 盲測設計：每門課混入 3 份課綱，由 5 位評分者辨識（本人 1、熟識者 2、不熟識之同領域學者 2）。不熟識者之辨識率不應顯著高於隨機

③ 學生問答重演（候選）

- 採用實際提問紀錄 10–20 題，由分身回覆後交本人判讀
- 具備當時之真實回覆可供對照，且無須重複施測
- 驗證情境與第一階段應用場景完全一致
- 另備 3 項候選任務，待確認後定案

所有任務均須計算真人評分者間一致性（Cohen's κ / ICC），以避免擬真度判定流於單一主觀印象。

系統架構 ④：釋出閘門

本專案產出



釋出閘門：本人評分通過門檻後方可釋出

本專案產出

01
系統出題
依各面向自動
產生初考題組

02
分身作答
由分身逐題回覆

03
本人評分
由本人判定是否貼近
自身觀點與思考風格

04
門檻判定
達門檻者釋出
未達者退回調整重測

05
釋出上線
列入可選分身清單
供他人對話

評分者為何必須是本人　「像不像我」屬於只有本人掌握的判準。他評與模型自評皆為替代指標，唯本人之判定可作為釋出與否的依據。

門檻數值與各面向權重待第一位對象試評後定案；本頁為架構圖第四格「釋出閘門」之展開，於三項驗證任務之後執行。

方法論風險：四項可預期質疑與對應說明

本專案產出

可預期之質疑	本專案之回應	現階段限制
無本人重測資料，如何區分誤差來自分身或本人自身不穩定	不宣稱正規化準確率，改報絕對一致率，並以其他對象之分身及不熟識本人之評分者作為基準線，據以區辨「像此人」與「像此類人」。	本人穩定度僅能引用文獻之 79.5%
單一對象，缺乏外推性	第一階段驗證對象為方法本身（協議能否區辨擬真程度），而非母體。第二位對象將選擇公開課程資料完整者，其課綱可作為天然對照。	須完成第二位對象方能正式回應
態度層準確度之實務價值為何	行為層於原文獻即已失效（ 0.03–0.11 ），本專案不予承諾；而規劃之應用場景本即落於態度層。	行為層為開放問題，目前尚無解法

另一項質疑為題目由研究團隊自訂。對策：出題人員與蒸餾人員分離、出題時點晚於蒸餾、課綱任務採用真實課綱對照。態度題庫初稿仍需第三方審題。

更新機制：分身所捕捉者為特定時點之特徵

本專案產出

理論缺口　現行架構擷取的是蒸餾當下的觀點與風格。然而本人對新技術、新局勢的看法會持續變動，分身若不更新，將逐漸偏離本人當前的判斷。

何者會變

- 對新技術、新事件的立場
- 研究重心與關注議題
- 舉例素材與時事引用

何者相對穩定

- 表達風格與句法習慣
- 推理方式與論證結構
- 核心價值與判斷原則

初步構想（待討論）

- 增量更新：定期補入新資料，重蒸餾易變層
- 時效標記：回覆標註所依據資料之時點
- 觸發條件：本人評分下滑或立場變動時重測

本項為現階段尚未解決之問題，列為後續研究重點；第一階段先以版本凍結與時點標記因應。

混淆因子實驗：底層模型影響風格，不影響立場

本專案產出



立場：四組完全一致

未載入人格資料之對照組亦產出相同主張

風格：差異顯著

篇幅差異 30% 源自模型；載入與否之差異僅 2.6%

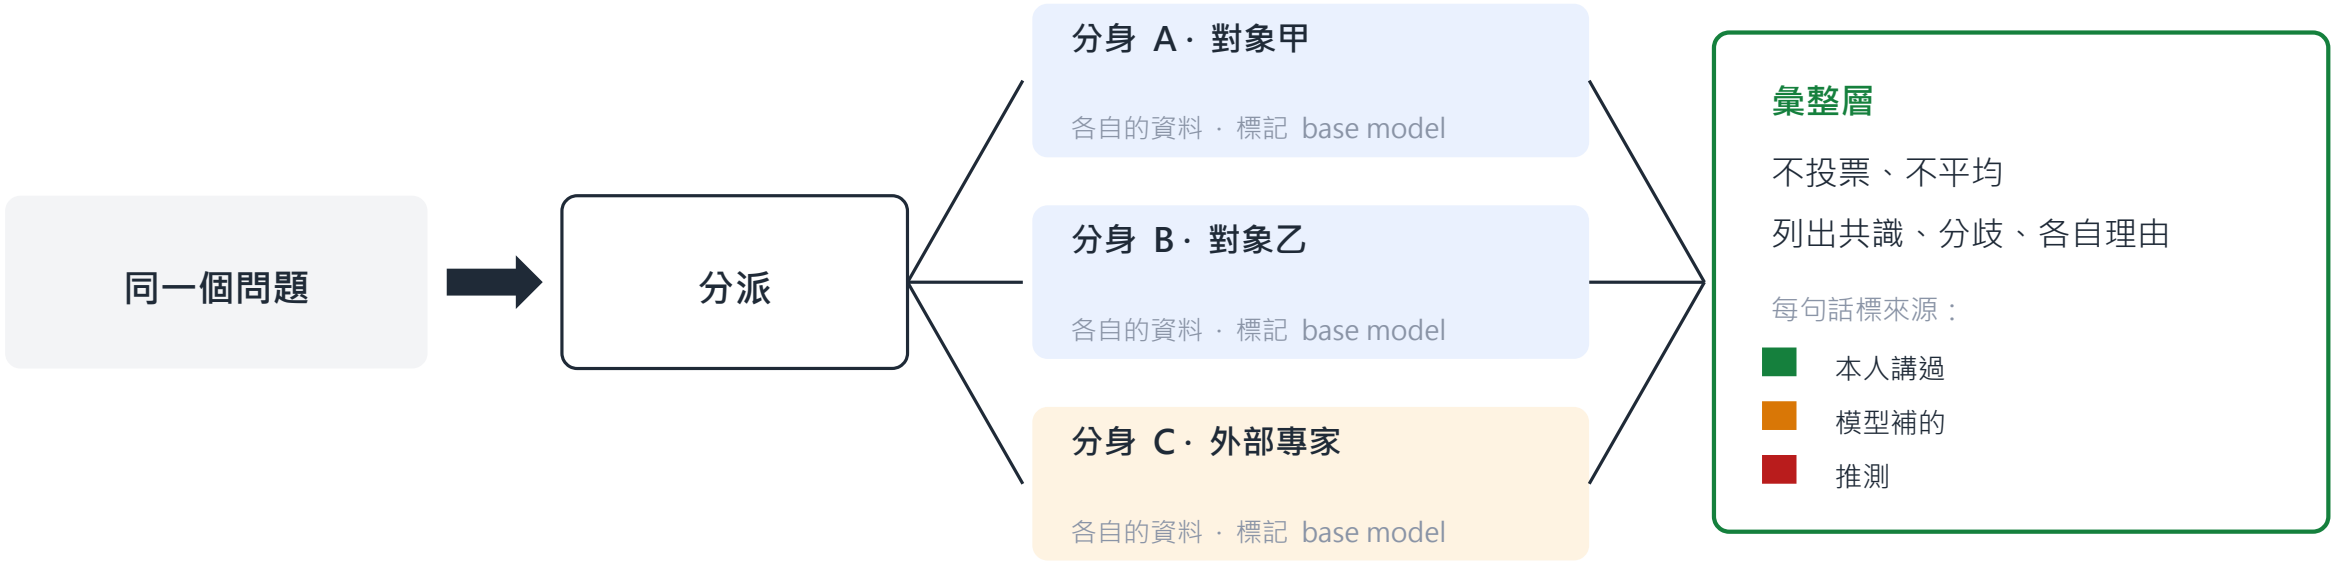
人格資料之實際貢獻：詞彙、句法與輸出紀律

設計結論：多分身系統應固定同一底層模型，方能確保觀點分歧來自人格資料而非模型差異。

本實驗規模： 3 個模型、 2 道題、每題單次作答；立場一致性之結論尚待擴大樣本確認。

延伸應用：多視角顧問團彙整不同分身的觀點

本專案產出



競品對標：八個既有案例均未公布擬真度評估

文獻既有

參考對象：台大電機 李宏毅教授

已實作 LLM 助教
1,028 名學生、GPT-4 批改 6 份作業，發表於 EMNLP 2024

曾試作 AI 授課影片，自評不及真人講解
該缺口正是本專案所欲蒸餾之講解邏輯與表達風格

驗證條件充足
公開影片 482 支、課程頁面 26 個，課綱具天然對照組

已有第三方開源專案以其為對象，本專案須明確區隔定位。

業界與學術界 8 項案例

均採指令工程結合檢索與形象合成
Praxis AI 、哈佛商學院、帝國理工、復旦、南京大學等，未進行模型微調

八案例均未公布擬真度正式評估
評估指標集中於使用率與學習成效

可借鑑之免標準答案路線
InCharacter（ ACL 2024 ）以量表訪談角色，對照第三方認知一致率 80.7%

國內目前未見已上線之特定人物數位分身案例。

市場缺口明確：實作案例眾多，但均未建立擬真度驗證機制。

重點參考： AI Andrew （ avatar.andrewng.org ）

文獻既有

值得注意之處　**該站主動聲明「 AI Andrew is not Andrew Ng 」，並明確區分分身回覆與本人觀點——此即責任邊界的揭露做法。**

該站自述之定位

- 定位為 intellectual companion （思想陪伴），非問答機器人
- 自述建於 Andrew Ng 之著述、教學與長年 AI 經驗
- 強調跨對話記憶：記得使用者的脈絡並主動追問未竟之事
- 具合成語音，網站明示並非本人錄音

與本專案之對照

- 互動形態與本專案第一階段目標一致
- 素材取自公開內容，屬蒸餾路線；本專案另取得本人自述
- 合成語音對應本專案第三階段規劃
- 同樣未見公布擬真度之正式評估

可借鑑　本專案亦應於分身介面明示「此為分身、非本人」，並標示語音為合成。此屬倫理揭露，與擬真度驗證同等重要。

資料來源： avatar.andrewng.org 網站說明與服務條款（ 2026-10 擷取 ）。該站未公布擬真度評估方法或數據。

未來規劃：語言、視覺、聲音三階段推進

本專案產出

第一階段 語言（ Language ）

現階段

建立以文字對話為主的數位分身，驗證核心架構與評估協議。

蒸餾流程	公開資料（演講、投影片、論文、逐字稿）+ 教授自述
測量工具	BFI-44 保留； AVP 訪談腳本改寫為中文學術場景版； GSS 整份替換為自製「專業領域態度題庫」
產出驗證	DISC + 課程框架任務 + 女媧評分卡

第二階段 VLM（視覺語言模型）

擴充至視覺模態 —— 讓分身能理解與產生投影片、圖表、板書等教學場景中的視覺內容。

第三階段 聲音（語音模仿）

重現本人的聲音與語調。技術與倫理複雜度均顯著較高，列為最後階段。

Q & A

Q & A

Q1 驗證層跟既有方法差在哪？

A 既有方法沒有這一層。個體差異以標準化量表量測，擬真度由真人盲測評定，不由模型自評。這是本專案相對既有做法的主要原創部分。

Q2 為什麼不請本人作答再重測就好？

A 原方法需作答數百題並於兩週後重測。除時間成本過高外，第二次作答時受測者已看過題目，獨立性已經喪失。改以情境任務觀察判斷方式，本人投入時間由 5 小時降至約 3 小時。

Q3 多個分身的意見不同，要怎麼整合？

A 不投票也不取平均。多視角架構的價值在於呈現不同框架對同一問題的解讀，取平均會使這個價值消失。輸出的是共識、分歧，以及各自的理由。

Q & A

Q1 多個分身可以用不同的底層模型嗎？

A 初期應固定同一個模型。實驗顯示底層模型會改變表達風格但不改變立場，若混用就無法分辨意見分歧來自人格資料還是模型差異。待量化模型間差異後再評估。

Q2 90 分算好嗎？

A 落在公開範例 89 至 97 的下緣。但該評分工具有 60 分是依模板撰寫即可取得，立場一致性維度在 15 份範例中全數滿分，不具鑑別力。90 分說明沒有漂移與捏造，不足以說明擬真度。

Q3 這項技術可以用在哪些場景？

A 落在態度層的場景可行：資深或退休員工的經驗留存、常見問題自動回覆、理念與判斷原則的傳承。不建議用於需要預測具體決策的場景。

謝謝大家